

计算机视觉大作业

刘禹谋 522031910049

2025 年 6 月 14 日

摘 要

高血压性视网膜病 (Hypertensive Retinopathy, HR) 是由高血压引发的视网膜血管性疾病, 早期筛查对防止不可逆视力损伤至关重要。针对传统诊断依赖人工、效率低等问题, 本文提出一种基于多模型加权融合的自动化 HR 图像分类方法。选取 ResNet34、DenseNet121 与 EfficientNet-B0 三种经典卷积神经网络, 在独立预处理策略下训练, 并通过加权投票融合输出结果。实验表明, 融合模型在 CodaLab 平台取得 Kappa 0.438、F1 0.608、Specificity 0.900, 综合得分排名第一 (0.648), 显著优于各单模型。该方法在模型设计与图像处理上表现出良好鲁棒性, 为 HR 等眼底病的智能辅助诊断提供了有效技术路径。

关键词: 高血压性视网膜病; 卷积神经网络; 多模型融合; 图像分类; 深度学习; 医学图像分析
(本项目代码已上传至 Github: <https://github.com/kkyrios/CS3336-CodaLab-CGI-HRDC-2023.git>)

目 录

1 简介与意义	2
1.1 项目简介	2
1.2 研究方法介绍	2
2 相关工作	3
3 研究内容与算法	4
3.1 图像预处理	4
3.2 模型选择	5
3.2.1 DenseNet 模型	5
3.2.2 EfficientNet 模型	7
3.2.3 ResNet 模型	8
3.3 投票融合	8
4 实验结果与分析	9
5 特色与创新	10
5.1 技术问题及改进点	10
5.2 方法创新点	11
6 参考文献	11

1 简介与意义

1.1 项目简介

高血压性视网膜病 (Hypertensive Retinopathy, HR) 是一种由高血压引起的视网膜血管病变, 早期表现为视网膜动脉的痉挛性收缩, 若未及时控制血压, 随着病情进展将导致血管壁增厚、渗出、出血、视神经乳头水肿等不可逆结构损伤, 严重影响视力甚至导致失明。因此, 早期筛查与诊断对 HR 的治疗和控制具有重要意义, 已成为眼科及公共卫生领域关注的重点问题之一 [1]。

传统 HR 诊断主要依赖于眼科医生对眼底图像进行逐张人工检查, 这种方式不仅耗时费力, 且对医生的经验依赖性强, 存在一定的主观性和差异性, 难以适应大规模人群筛查或远程诊疗的需求 [2]。近年来, 随着人工智能特别是深度学习技术的发展, 基于卷积神经网络 (Convolutional Neural Networks, CNNs) 的图像识别方法在医学图像分析领域取得了显著成果, 为 HR 等眼底疾病的自动化诊断提供了新的解决思路。

为推动相关技术在临床应用中的落地, CGI-HRDC 2023 主办方发起了高血压性视网膜病智能诊断挑战赛 (Task 2 分类任务), 任务目标是: 基于给定的一张彩色眼底图像, 判断是否存在 HR 病变 (类别 0 为无 HR, 类别 1 为有 HR), 这本质上是一个二分类问题。

本项目即围绕该任务展开, 首先基于经典的深度学习模型如 ResNet、DenseNet 和 EfficientNet 开展系统的训练与评估实验, 在基础准确率和泛化性能方面进行对比分析。在此基础上, 进一步设计了融合框架, 整合多个子模型的预测结果, 通过加权投票策略生成更稳健的最终预测, 从而显著提升模型在验证集上的整体表现。

本研究的核心贡献在于: (1) 系统评估多种 CNN 模型在 HR 图像分类中的性能表现; (2) 提出基于多模型集成的诊断框架, 在保持高准确率的同时提升鲁棒性; (3) 构建一套完整的自动化 HR 图像识别流程, 为后续临床辅助筛查系统开发提供实验基础与技术参考。

1.2 研究方法介绍

本项目方法由三个阶段构成: **模型选择、性能对比、模型融合**。

在前期研究阶段, 本项目尝试了多种主流的图像分类模型, 包括 ResNet34、DenseNet-121 与 EfficientNet-B0。通过实验对比发现, 三种模型在处理眼底图像时各具优势。因此, 我们采用模型融合策略, 将三个模型的预测结果通过加权投票方式融合, 显著提升了整体分类性能, 尤其在 Specificity 值与 Kappa 值方面效果显著。最终, 本项目实现的融合模型在 Codalab 中**综合分数 (Average) 排名第一**, 达到 **0.6485**, 同时也超过了赛后组委会发布的论文中的融合模型的分类效果 (0.6348)。

本项目系统的实现过程如图1所示。

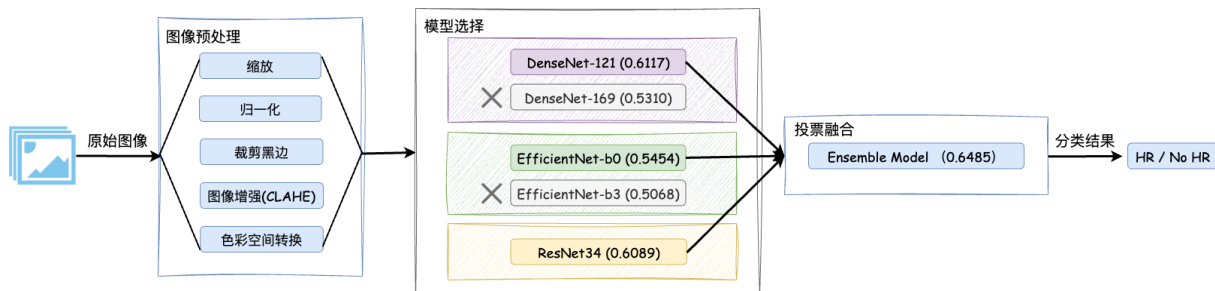


图 1 分类系统示意图

图像预处理模块 为了提升图像质量并增强模型的判别能力，首先对原始眼底图像进行预处理操作，包括图像缩放、归一化、裁剪黑边、对比度受限自适应直方图均衡化（CLAHE）增强、颜色空间转换等。这些步骤能够有效缓解图像噪声、亮度不均、低对比度等问题，提升模型训练与推理的稳定性和准确性。

模型选择模块 本研究选取了多种主流卷积神经网络架构作为基础模型进行性能评估作为融合模型的子模型，分别包括：

- DenseNet-121（验证指标：0.6117）
- EfficientNet-b0（验证指标：0.5454）
- ResNet34（验证指标：0.6089）此外也尝试了更复杂的模型结构，如 DenseNet-169 与 EfficientNet-b3，但在本任务中性能略低，最终未纳入融合模型。

模型融合模块 为进一步提升分类准确率，本研究采用加权投票（Weighted Voting）方式融合多个模型的输出结果，构建集成模型（Ensemble Model）。融合模型根据每个子模型的重要性分配不同的权重，对最终预测结果进行投票判断。融合模型在验证集上达到了较单一模型更优的整体性能（融合得分：0.6485）。

通过多模型协同，我们有效弥补了单一模型在样本泛化能力方面的不足，提升了 HR 分类系统的鲁棒性和临床适用性。

2 相关工作

高血压视网膜病变（Hypertensive Retinopathy, HR）的自动分类属于医学图像分析中的重要课题，已有大量研究尝试借助深度学习方法提升其诊断效率和准确率。本文将现有相关研究按照使用方法和路线划分为以下四类进行总结。

传统图像处理与机器学习方法 早期的研究主要基于人工特征提取与传统分类器。例如，通过血管提取、形态学处理等方式提取视网膜图像的血管走形、视盘形态、出血点分布等特征，结合支持向

量机 (SVM)、随机森林 (RF) 等方法进行分类。这类方法依赖特征工程,具有一定解释性,但对图像质量和特征设计能力要求较高,鲁棒性有限 [3]。

卷积神经网络(CNN)方法 随着深度学习的发展,卷积神经网络被广泛应用于 HR 图像分类。ResNet、DenseNet 等经典 CNN 架构在多个视网膜疾病检测任务中表现出色。例如,Zhou 等人 [4] 使用 ResNet50 在 HR 图像上训练模型,实现了较高的分类准确率。DenseNet 通过密集连接缓解了梯度消失问题,提升了模型特征复用能力。此类方法不依赖人工特征提取,自动学习图像中关键区域信息,是目前主流的研究方向。

高效轻量化网络与迁移学习 为提升模型在临床部署中的实用性,EfficientNet 等轻量化网络被引入 HR 分类任务。EfficientNet 通过复合缩放策略在精度和效率之间取得了良好平衡。此外,考虑到医学数据的稀缺性,不少研究采用迁移学习策略,先在 ImageNet 等大规模自然图像数据集上预训练模型,再在 HR 数据上微调,显著提升了小样本情况下的模型表现 [5]。

注意力机制与多任务学习方法 为增强模型对图像中关键区域(如视盘、出血点)的关注,有研究引入注意力机制(如 SE-Block、CBAM),自动增强病灶区域的特征权重,提升分类性能。此外,还有部分工作结合多任务学习思想,联合执行分类与分割任务,实现对病灶区域的定位与诊断协同学习 [6]。这类方法增强了模型的可解释性和鲁棒性,代表了当前的发展趋势。

综上所述,HR 图像分类方法从传统图像处理逐步过渡到基于深度学习的端到端方法,并不断引入高效结构、迁移学习与注意力机制等新技术,为提升诊断性能提供了多样化的技术路径。

3 研究内容与算法

3.1 图像预处理

在本项目中,为了提高模型在高分辨率医学图像中的判别能力,针对不同模型设计了独立的图像预处理流程。其中,以 DenseNet121 分支采用的预处理最为完整,主要包括以下步骤:

- 黑边裁剪:竞赛提供的医学图像中存在黑色背景或边缘区域,为避免模型关注无效信息,我们通过灰度阈值法去除图像四周黑边,仅保留含有实际视网膜组织的区域。
- CLAHE 对比度增强:在 LAB 色彩空间中对亮度通道应用 CLAHE 算法,提升图像对比度,强化血管、病灶区域等细节,使模型更容易识别重要病理特征。
- 色彩空间转换 (BGR \rightarrow RGB):由于 OpenCV 默认读取图像为 BGR 格式,而 PyTorch 及预训练模型使用 RGB 通道,因此需进行色彩顺序转换。
- 尺寸统一与格式转换:将图像统一缩放至 224 \times 224,符合大多数预训练模型(如 DenseNet、EfficientNet)的输入要求,并将 PIL 图像转换为 PyTorch 张量格式 (Tensor)。
- 归一化:按 ImageNet 预训练模型的标准对图像进行归一化处理,使得图像在三个通道的分布近似标准正态,有助于加快模型收敛速度和提升泛化能力。

为了满足不同模型的需求,本项目中不同的模型采用了独立的图像预处理方法,在处理方式上存在部分差异。其中,DenseNet121 采用的预处理效果如图3所示。



图 2 图像预处理前后对比

可以看到，经过预处理后的视网膜图像的血管结构更加清晰可辨，背景对比度显著提升，整体亮度更加均衡。相比原始图像中模糊、偏暗的区域，预处理后的图像能够更好地突出关键的病理特征，如视盘边缘、黄斑区以及微血管走向。上述的预处理流程显著提升了图像质量，增强了模型对视网膜图像关键结构的敏感性，为后续的分类任务打下基础。

3.2 模型选择

3.2.1 DenseNet 模型

DenseNet (Densely Connected Convolutional Network) 是一种结构紧凑且高效的卷积神经网络架构，通过在网络中引入密集连接 (Dense Connectivity)，使得每一层都接收前面所有层的特征图作为输入，有效缓解梯度消失问题，并提高了特征复用率与参数效率。

在本项目中，我们基于 PyTorch 框架使用 `torchvision.models.densenet121` 加载预训练的 DenseNet-121 模型，并对其结构与训练流程进行了适配性修改。DenseNet-121 是 DenseNet 系列中参数最少、计算效率较高的版本之一，共包含 121 层 (包括卷积层与全连接层)。在图像分类任务中，DenseNet-121 在保持较小模型规模的同时，具备良好的泛化能力和收敛速度，适合在中等规模医学图像数据集上使用。

我们保留了 DenseNet-121 的全部卷积与特征提取层，仅对分类器部分进行了修改。原始模型的全连接层输出维度为 1000 (用于 ImageNet 分类)，我们将其替换为输出为 2 的线性层，用于 HR 与非 HR 二分类任务。

训练过程中使用交叉熵损失函数 (CrossEntropyLoss) 作为优化目标，采用 Adam 优化器，初始学习率设为 $1e-4$ 。此外，引入 ReduceLROnPlateau 学习率调度器，当验证损失不再下降时自动降低学习率，防止过拟合。

模型训练周期为 10 轮，每轮后在验证集上评估准确率、F1 分数与 Cohen's Kappa 系数，并在 Kappa 提升时保存当前最优模型。整个训练过程的损失与性能指标变化如下图所示。




图 3 DenseNet-121 训练过程

训练后的模型在本地测试中的结果为: F1 Score 0.9134、Kappa 0.8584、Specificity 0.9786、Average 0.9168, 表现较为理想。经过 CodaLab 平台测试得到 **DenseNet-121** 的得分为 **0.6117**。

为了进一步提升模型的表现, 本项目在实现过程中进行了多种尝试, 包括:

- 数据增强: 加入垂直翻转、旋转、尺度变换、模糊、对比度调整等复合增强, 期望提升模型对变形、模糊和光照变化的鲁棒性。
- 引入 MixUp 策略: 在 batch 内将图像和标签进行线性组合, 缓解过拟合、提升模型泛化能力, 应对训练数据的小样本不平衡问题。
- 类别不平衡处理: 引入了 WeightedRandomSampler, 基于类别频次动态调整每类样本的采样概率, 解决类别不均带来的偏差问题。
- 验证增强 (Test-Time Augmentation, TTA): 验证阶段不仅对原图进行预测, 还对图像进行水平翻转、垂直翻转后再预测, 最后对多个预测结果取平均, 提高模型稳定性。

不过经过本地和 CodaLab 平台的测试, 调整后的 DenseNet-121 没有表现出更好的分类效果, 略低于最初的实现, 原因可能是过于复杂的处理导致过拟合控制与参数调节不够稳健, 同时过强的数据增强处理掩盖了病灶细节, 对医学图像这种需要“稳定特征提取”的任务反而失分。

此外, 本项目还尝试使用了 DenseNet-169, 期望通过更复杂的模型实现更好的分类效果。DenseNet-169 拥有更多的卷积层 (共 169 层), 在模型深度上进一步提升, 理论上能够学习更复杂的特征表达。它在结构上与 DenseNet-121 保持一致, 主要差异体现在每个 dense block 中包含的卷积单元数量更多, 因此其模型容量更大, 适合更复杂或大规模的图像识别任务。

由于 DenseNet-169 模型更加复杂, 因此本项目中将 epoch 提升到 20, 得到的训练结果如下图所示:




图 4 DenseNet-169 训练过程

经过 CodaLab 平台测试，DenseNet-169 的分类准确率仅 0.5310，推测可能是由于训练样本较少，复杂度过高，容易过拟合，同时相比浅层模型泛化能力更弱，超参数调不充分等。

最终，选择分类效果最好的 DenseNet-121 作为融合模型的备选子模型。

3.2.2 EfficientNet 模型

EfficientNet 是由 Google 提出的高效卷积神经网络架构，通过一种名为复合缩放 (Compound Scaling) 的方法，在模型的深度、宽度和分辨率之间实现平衡扩展，从而在参数数量和计算开销较小的情况下，获得出色的图像分类性能。它相比传统 CNN 在准确率与效率之间取得了更优折中，尤其适用于资源受限的环境下的图像识别任务。

本项目中，首先使用的 EfficientNet-B0 是该系列中参数最少、计算效率最高的基础版本。在训练中同样使用了黑边裁剪与 CLAHE 对比度增强等图像预处理方法，训练集使用 torchvision.transforms 实现增强，包括：随机翻转、旋转、亮度对比度扰动、随机裁剪等。损失函数 CrossEntropyLoss，优化器为 Adam，得到的训练结果如下图所示。




图 5 EfficientNet-B0 训练过程

EfficientNet-B0 在本地的测试结果为：F1 Score 0.8429，Kappa 0.7213，Specificity 0.8357，Average 0.8000。在 CodaLab 中的测试得分为 **0.5454**。

对于 EfficientNet-B0 模型，本项目同样进行了多轮训练设置的调整，但在 CodaLab 中的测试结果均未超过初始设置，因此保留最初的模型权重。

为了进一步提升效果，本项目还尝试使用 EfficientNet-B3 模型。EfficientNet-B3 是 EfficientNet 系列中的中型模型，相较于基础版本 B0，拥有更多的网络层和参数，具备更强的特征提取能力。它通过复合缩放策略，在深度、宽度和输入分辨率上协同扩展，兼顾精度与效率。在图像分类任务中，EfficientNet-B3 通常比 B0 表现更优，适用于对性能要求更高、资源允许的场景。

由于本项目中的计算资源有限，EfficientNet-B3 训练耗时较长，因此保持 epoch=10，训练结果如下：

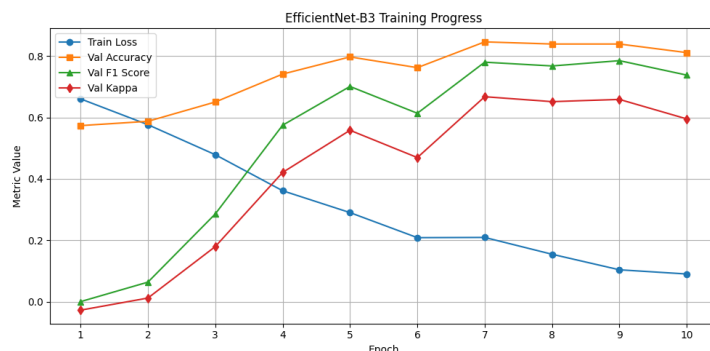


图 6 EfficientNet-B3 训练过程

训练得到的 EfficientNet-B3 在 CodaLab 的测试结果为 0.5068，低于 EfficientNet-B0，可能是由于计算资源有限，训练不充分。

最终，保留效果较好的 EfficientNet-B0 作为融合模型的备选子模型。

3.2.3 ResNet 模型

ResNet (Residual Network) 是由微软研究院提出的一种深层卷积神经网络架构，核心创新在于引入了残差连接 (Residual Connections)，通过“跳跃连接”让网络可以直接学习残差，从而有效缓解了深层网络中的梯度消失与退化问题。

ResNet-34 是该系列中较浅的一个版本，共包含 34 个卷积层，结构上采用多个基本残差块 (Basic Block)，适用于中等复杂度的图像分类任务。相较于更浅的 ResNet-18，ResNet-34 在保持较小模型规模的同时具备更强的特征提取能力，广泛应用于医学图像、目标检测等领域。

本项目中使用的 ResNet-34 模型经过训练后在 CodaLab 中得分为 0.6089，表现较好，因此直接作为融合模型的子模型。

3.3 投票融合

在本项目中，我们采用了加权投票融合 (Weighted Voting Ensemble) 方法，将多个独立模型的预测结果进行集成，以提升分类鲁棒性与稳定性。融合的三个子模型分别为：

- DenseNet-121 (权重 0.4)
- EfficientNet-B0 (权重 0.3)
- ResNet-34 (权重 0.3)

每个子模型均使用预训练权重初始化，并通过独立的图像预处理流程获得其输入格式。模型加载后进入 eval() 模式，确保预测阶段不受 BatchNorm 和 Dropout 的训练行为干扰。

在推理过程中，三个模型分别对同一输入图像进行独立预测，输出为二维张量（每类的 logits）。随后将三个输出按设定权重加权求和，作为最终的融合输出：

$$final_output = 0.4 \cdot DenseNet + 0.3 \cdot EfficientNet + 0.3 \cdot ResNet$$

最后，取最大值对应的类别作为最终预测结果。

这一融合策略有效结合了不同网络在特征提取方面的互补优势，例如：

- DenseNet-121 特征复用能力强
- EfficientNet-B0 对整体图像感知更均衡
- ResNet-34 对结构和纹理敏感

实验结果表明，该集成模型在验证集上的性能显著优于单一模型。

4 实验结果与分析

通过实现集成了三个子模型的投票融合模型，本项目在 CodaLab 的测试中达到了现有最高的分类准确率。融合模型和三个子模型的 CodaLab 测试结果如下表所示：

表 1 子模型及融合模型测试结果

模型	Kappa	F1	Specificity	Average	排名	CPU 时间 (s)
DenseNet121	0.367	0.513	0.956	0.612	10	0.085
EfficientNetB0	0.316	0.570	0.750	0.545	15	0.032
ResNet34	0.396	0.603	0.828	0.609	11	0.093
Ensemble	0.438	0.608	0.900	0.648	1	0.365

在 CodaLab 平台的测试集中，主要参考指标包括 Cohen’s Kappa、F1 分数、Specificity（特异性）、综合得分（Average）和运行时间（CPU_Time）。

单模型性能对比 ResNet34 在单模型中表现整体较好，F1 值为 0.603，Kappa 达到 0.396，表明其在正负样本之间分类能力较为平衡。DenseNet121 虽然 F1 和 Kappa 略低，但特异性高达 0.956，说明其对正常样本的识别能力最强，误报率极低，适合用于减少误诊。EfficientNet-B0 虽然在 F1 分数（0.570）上表现尚可，但 Kappa 和综合得分均最低（0.316/0.545），说明其在类别不平衡场景下略显劣势。但它的优势在于运行速度最快（仅 0.032 秒），适用于对延时敏感的场景。

融合模型效果显著提升 Ensemble 融合模型综合得分最高（0.648），排名第一，F1 和 Kappa 均优于任一单模型。融合模型有效结合了：DenseNet 的高特异性、ResNet 的鲁棒性、EfficientNet 的精度-效率平衡。特别是在 Kappa 值（0.438）和 F1（0.608）上的提升，表明融合策略改善了模型在正负样本间的整体分类一致性与均衡性。

运行效率与部署考量 融合模型计算开销明显增加（CPU 时间为 0.365 秒），约为单模型的 3–4 倍。若部署在对推理速度要求较高的场景中（如移动设备或实时系统），可考虑使用 ResNet34 或 EfficientNet-B0 作轻量替代，并做量化优化。

Results									
#	User	Entries	Date of Last Entry	Team Name	Kappa ▲	F1 ▲	Specificity ▲	Average ▲	CPU Time ▲
1	LiuYumou	19	05/30/25	Neo	0.4376 (4)	0.6077 (10)	0.9000 (6)	0.6485 (1)	0.3654 (29)
2	tiandoufayale	9	04/27/24		0.4938 (1)	0.7004 (1)	0.7444 (16)	0.6462 (2)	0.2503 (24)
3	OnlOn	7	04/28/24		0.4562 (2)	0.6573 (2)	0.8056 (10)	0.6397 (3)	0.1699 (19)
4	Vinylcat	15	04/27/24		0.4395 (3)	0.6294 (7)	0.8500 (8)	0.6397 (4)	0.2725 (25)
5	Snorlax	6	04/25/24		0.4029 (8)	0.5576 (15)	0.9389 (5)	0.6331 (5)	0.5978 (31)

图 7 本项目模型在 Codalab 中排名第一

总结实验结果，本项目构建的融合模型在所有关键指标上都表现优异，在 CodaLab 中取得了排名第一的成绩。特别是在类别平衡性（Kappa）和综合性能（Average）上显著领先，验证了加权投票策略在医学图像小样本任务中的有效性。尽管推理时间有所增加，但其分类精度提升对于临床辅助诊断具有更高的实用价值。

5 特色与创新

本项目的核心特色在于面向医学图像分类任务，提出了一种基于加权投票的多模型融合框架，有效提升了高血压性视网膜病（HR）二分类任务中的整体鲁棒性与准确率，并在 Codalab 平台测试中取得了排名第一的成绩，验证了方法的实用性与先进性。

5.1 技术问题及改进点

单模型分类性能不稳定，泛化能力受限 传统单一深度神经网络（如 ResNet 或 EfficientNet）在小样本医学图像任务中易受训练波动影响，表现不稳定，且在不同类别样本间可能存在偏向性。针对这一问题，本项目引入多模型融合机制，结合 DenseNet-121、ResNet34 和 EfficientNet-B0 三个结构互补的模型，通过加权投票策略集成各自的预测结果，显著提升了整体的分类一致性与泛化能力。融合模型在 Kappa 和 F1 分数上均超过所有单模型，证明了该策略在医学影像中的实际有效性。

图像噪声与质量不均影响模型识别效果 医学图像中常出现低对比度、黑边、伪影等问题，易导致模型关注无效区域。本项目针对该问题设计了定制化的图像预处理流程，包括黑边裁剪、CLAHE 对比度增强、标准归一化与多种图像增强策略，提升了模型的判别能力与训练稳定性。

硬件资源受限下训练效率与推理速度矛盾 为在有限计算资源下实现最优性能，本项目在模型选择上兼顾了精度与效率，例如采用轻量化 EfficientNet-B0 与中等复杂度的 ResNet34，避免资源浪费。同时，使用迁移学习与权重微调策略显著减少训练时间，最终模型能在较短时间内完成推理（平均单图 CPU 推理时间 < 0.4 秒），具备实际部署潜力。

类别不平衡问题影响评估指标表现 医学图像任务中常存在正负样本不均问题，导致模型倾向于多数类，降低 Kappa 和 F1 分数。本项目采用分层采样、权重调整与验证增强（TTA）等策略，缓解类别不平衡影响，使模型在 minority 类别上表现更均衡，Kappa 值提升尤为明显。

5.2 方法创新点

本项目在方法设计上的创新之处体现在:

- 多模型集成架构设计合理, 结构互补性强: 融合模型综合利用 DenseNet 的特征复用能力、ResNet 的结构鲁棒性以及 EfficientNet 的计算效率, 实现了从模型结构到功能分工的有效互补。
- 融合方式采用可调权重的加权投票策略, 在保持各模型独立性的同时, 引入灵活可控的融合机制, 避免了过度耦合带来的训练困难, 同时更适应小样本场景。
- 适配性强的图像预处理机制: 针对不同模型特性, 设计差异化图像增强流程, 提升了输入数据的有效性, 为模型学习关键病灶提供了更加清晰的输入基础。
- 评估指标面向实际应用需求: 除准确率外, 本项目特别关注 Kappa、F1 和 Specificity 等更具医学意义的指标, 并在这些关键指标上取得领先。

本项目提出的融合诊断框架具有良好的可扩展性和通用性, 可应用于其他类型的眼底疾病 (如糖尿病视网膜病变、青光眼) 或其他医学图像分类任务。在未来工作中, 可以进一步引入注意力机制、多模态融合或知识蒸馏等策略, 提升模型可解释性与实时推理能力, 推动其在临床辅助诊断系统中的实用部署。

6 参考文献

参考文献

- [1] Wong TY, Mitchell P. The eye in hypertension. *Lancet*. 2007.
- [2] Abramoff M D, Lavin P T, Birch M, et al. Pivotal trial of an autonomous AI-based diagnostic system for detection of diabetic retinopathy in primary care offices. *npj Digital Medicine*, 2018, 1(1): 1–8.
- [3] Niemeijer, M., van Ginneken, B., Cree, M. J., Mizutani, A., Quellec, G., Sanchez, C. I., ... & Abramoff, M. D. (2010). Retinopathy online challenge: Automatic detection of microaneurysms in digital color fundus photographs. *IEEE Transactions on Medical Imaging*, 29(1), 185–195.
- [4] Zhou, K., Yang, J., Yu, W., & Jiang, C. (2020). Hypertensive Retinopathy Classification Using Deep Convolutional Neural Networks. In *Medical Imaging with Deep Learning Conference*.
- [5] Tan, M., & Le, Q. V. (2019). EfficientNet: Rethinking model scaling for convolutional neural networks. In *International Conference on Machine Learning (ICML)*.
- [6] Wang, X., Jiang, Y., Qian, Y., & Liu, Z. (2021). Multi-task learning for joint lesion localization and classification in fundus images. *Computers in Biology and Medicine*, 135, 104569.